

# **Сингулярное разложение и главные компоненты**

# Обобщение диагонализации

# Краткий план:

- Жорданова нормальная форма.

# Краткий план:

- Жорданова нормальная форма.
- Сингулярное разложение.

# Краткий план:

- Жорданова нормальная форма.
- Сингулярное разложение.
- Доказательство существования.

# Не все матрицы диагонализуемы

## Утверждение

Квадратная матрица  $A$  размера  $n \times n$  диагонализуема, если у неё найдётся  $n$  линейно независимых собственных векторов.

В этом случае  $A$  представима в виде  $A = PDP^{-1}$ , где  $P$  — матрица из собственных векторов,  $D$  — диагональная матрица из собственных значений.

# Не все матрицы диагонализуемы

## Утверждение

Квадратная матрица  $A$  размера  $n \times n$  диагонализуема, если у неё найдётся  $n$  линейно независимых собственных векторов.

В этом случае  $A$  представима в виде  $A = PDP^{-1}$ , где  $P$  — матрица из собственных векторов,  $D$  — диагональная матрица из собственных значений.

## Утверждение

У симметричной матрицы  $A$  размера  $n \times n$  найдётся  $n$  ортогональных собственных векторов единичной длины.

С их помощью матрица  $A$  представима в виде

$$A = PDP^T.$$

# А если не везёт?

Что делать, если у матрицы  $A$  размера  $n \times n$  меньше, чем  $n$  независимых собственных векторов?

# А если не везёт?

Что делать, если у матрицы  $A$  размера  $n \times n$  меньше, чем  $n$  независимых собственных векторов?

## Утверждение

Любая квадратная матрица  $A$  представима в виде

$$A = PJP^{-1},$$

где **жорданова нормальная форма**  $J$  содержит на диагонали жордановы клетки  $J_i$ :

$$J = \begin{pmatrix} J_1 & 0 & \dots & 0 \\ 0 & J_2 & \dots & 0 \\ \dots & \dots & \dots & 0 \\ 0 & 0 & \dots & J_k \end{pmatrix}, \quad J_i = \begin{pmatrix} \lambda_i & 1 & \dots & 0 \\ 0 & \lambda_i & \dots & 0 \\ 0 & \dots & \dots & 1 \\ 0 & 0 & \dots & \lambda_i \end{pmatrix}$$

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растворение компонент вектора в  $\mathbb{R}^k$ .

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растворение компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растворение компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.
4. Ортогональное преобразование из  $\mathbb{R}^n$  в  $\mathbb{R}^n$ . Сохраняет длины векторов и углы между ними.

# Сингулярное разложение

## Утверждение

Любой линейный оператор из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  представляет собой последовательность действий:

1. Ортогональное преобразование из  $\mathbb{R}^k$  в  $\mathbb{R}^k$ . Сохраняет длины векторов и углы между ними.
2. Растворение компонент вектора в  $\mathbb{R}^k$ .
3. Переход из  $\mathbb{R}^k$  в  $\mathbb{R}^n$  путём дописывания нулей в вектор, или зачёркивания части координат.
4. Ортогональное преобразование из  $\mathbb{R}^n$  в  $\mathbb{R}^n$ . Сохраняет длины векторов и углы между ними.

Все эти действия мы рассмотрели на первой лекции!

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $v_1, v_2, \dots, v_k$  в  $M$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $\mathbf{v}_{k+1}, \dots, \mathbf{v}_n$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $v_1, v_2, \dots, v_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $v_{k+1}, \dots, v_n$ .

1. Повернём-отразим пространство, чтобы  $v_1, \dots, v_n$  перешли в  $e_1, \dots, e_n$ .

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $v_1, v_2, \dots, v_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $v_{k+1}, \dots, v_n$ .

1. Повернём-отразим пространство, чтобы  $v_1, \dots, v_n$  перешли в  $e_1, \dots, e_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $v_1, v_2, \dots, v_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $v_{k+1}, \dots, v_n$ .

1. Повернём-отразим пространство, чтобы  $v_1, \dots, v_n$  перешли в  $e_1, \dots, e_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.
3. Смены размерности нет.

# Сингулярное разложение проекции

Оператор  $H : \mathbb{R}^n \rightarrow \mathbb{R}^n$  проецирует векторы на линейную оболочку  $M$ .

Выберем ортогональный базис  $v_1, v_2, \dots, v_k$  в  $M$ .

Дополним его до ортогонального базиса в  $\mathbb{R}^n$  векторами  $v_{k+1}, \dots, v_n$ .

1. Повернём-отразим пространство, чтобы  $v_1, \dots, v_n$  перешли в  $e_1, \dots, e_n$ .
2. Домножим первые  $k$  компонент вектора на 1, а остальные на 0.
3. Смены размерности нет.
4. Повернём-отразим пространство, чтобы  $e_1, \dots, e_n$  перешли в  $v_1, \dots, v_n$ .

# Сингулярное разложение

## Утверждение

Любую матрицу  $A$  размера  $n \times k$  можно представить в виде

$$A = U\Sigma V^T,$$

где матрица  $U$  размера  $n \times n$  — ортогональная,  $U^T U = I$ ,  
матрица  $V$  размера  $k \times k$  — ортогональная,  $V^T V = I$ ,  
матрица  $\Sigma$  размера  $n \times k$  — диагональная.

# Сингулярное разложение

## Утверждение

Любую матрицу  $A$  размера  $n \times k$  можно представить в виде

$$A = U\Sigma V^T,$$

где матрица  $U$  размера  $n \times n$  — ортогональная,  $U^T U = I$ ,  
матрица  $V$  размера  $k \times k$  — ортогональная,  $V^T V = I$ ,  
матрица  $\Sigma$  размера  $n \times k$  — диагональная.

Данное разложение также называется *SVD-разложением*,  
*singular value decomposition*.

# Присмотримся к матрицам

Если  $n \geq k$ , то  $SVD$ -разложение примет вид

$$A = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \cdot \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} -\mathbf{v}_1^T- \\ \vdots \\ -\mathbf{v}_k^T- \end{pmatrix}$$

# Присмотримся к матрицам

Если  $n \geq k$ , то  $SVD$ -разложение примет вид

$$A = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \cdot \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} -\mathbf{v}_1^T- \\ \vdots \\ -\mathbf{v}_k^T- \end{pmatrix}$$

Числа  $\sigma_i$  называются **сингулярными** числами матрицы  $A$ .

# Зачем нужно $SVD$ -разложение?

Сильно упрощает многие вычисления.

# Зачем нужно $SVD$ -разложение?

Сильно упрощает многие вычисления.

Показывает внутренний мир матрицы.

# Зачем нужно $SVD$ -разложение?

Сильно упрощает многие вычисления.

Показывает внутренний мир матрицы.

Существует быстрая и устойчивая итеративная процедура  
нахождения  $SVD$ -разложения.

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

Сингулярное разложение для  $A^T A$ :

$$A^T A = V\Sigma^T U^T \cdot U\Sigma V^T = V\Sigma^T \Sigma V^T$$

# Раскладываем все матрицы!

Сингулярное разложение для  $A^T$ :

$$A^T = (U\Sigma V^T)^T = V\Sigma^T U^T$$

Сингулярное разложение для  $A^T A$ :

$$A^T A = V\Sigma^T U^T \cdot U\Sigma V^T = V\Sigma^T \Sigma V^T$$

Сингулярное разложение для  $AA^T$ :

$$AA^T = U\Sigma V^T \cdot V\Sigma^T U^T = U\Sigma \Sigma^T U^T$$

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = VDV^T$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .
3. Осталось найти  $U$  из целевого разложения:

$$A = U\Sigma V^T$$

# Существование разложения

Наша задача предъявить разложение  $A = U\Sigma V^T$ .

Для удобства будем считать, что  $n \geq k$ .

## Доказательство

1. Матрица  $A^T A$  является матрицей Грама. Она положительно определена и симметрична. А потому представима в виде  $A^T A = V D V^T$ .
2. Диагональные элементы  $D$  неотрицательны. Поэтому  $D$  представима в виде  $\Sigma^T \Sigma$ .
3. Осталось найти  $U$  из целевого разложения:

$$A = U\Sigma V^T \text{ или } AV = U\Sigma$$

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = A v_1 / \sigma_1,$$

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = A v_1 / \sigma_1, \quad u_2 = A v_2 / \sigma_2, \dots$$

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = A v_1 / \sigma_1, \quad u_2 = A v_2 / \sigma_2, \dots$$

5. Вектора  $v_i$  кончатся раньше  $u_i$ .

# Существование разложения

Уже нашли  $\Sigma$  и  $V$ . Осталось найти  $U$  из  $AV = U\Sigma$ .

## Окончание доказательства

4. Находим вектора  $u_i$  по очереди:

$$u_1 = A v_1 / \sigma_1, \quad u_2 = A v_2 / \sigma_2, \dots$$

5. Вектора  $v_i$  кончатся раньше  $u_i$ . Оставшиеся  $u_{k+1}, \dots, u_n$  выберем произвольными, чтобы  $U$  была ортогональной матрицей.

# Авторы современного алгоритма

Джин Говард Голуб



Уильям Мортон Кэхэн



Отец плавающей точки

## **Поиск SVD разложения**

**Это видеофрагмент с доской, слайдов здесь нет :)**

## **Нахождение проекции при известном SVD**

**Это видеофрагмент с доской, слайдов здесь нет :)**

# **Немного статистики**

# Краткий план:

- Выборочная дисперсия.

# Краткий план:

- Выборочная дисперсия.
- Стандартизация.

# Краткий план:

- Выборочная дисперсия.
- Стандартизация.
- Выборочная корреляция.

# Центрирование

## Определение

Для вектора чисел  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

# Центрирование

## Определение

Для вектора чисел  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

## Определение

**Центррирование переменной** — переход от набора чисел  $(x_1, x_2, \dots, x_n)$  к набору чисел  $(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$ .

# Центрирование

## Определение

Для вектора чисел  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  **выборочным средним** называют величину

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}.$$

## Определение

**Центрирование переменной** — переход от набора чисел  $(x_1, x_2, \dots, x_n)$  к набору чисел  $(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$ .

Пример.  $(4, 2, 3, 3) \rightarrow (1, -1, 0, 0)$ .

# Свойства центрирования

## Утверждение

Если  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ ,  $y_i = x_i - \bar{x}$ , то  
 $\bar{x}' = 0$ .

# Свойства центрирования

## Утверждение

Если  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

# Свойства центрирования

## Утверждение

Если  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

С геометрической точки зрения:

$(\bar{x}, \bar{x}, \dots, \bar{x})$  — проекция вектора  $\mathbf{x}$  на  $\text{Span } \mathbf{v}$ , где  $\mathbf{v} = (1, 1, \dots, 1)$ .

# Свойства центрирования

## Утверждение

Если  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ ,  $y_i = x_i - \bar{x}$ , то  $\bar{x}' = 0$ .

$$\sum_{i=1}^n x'_i = \sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = 0$$

С геометрической точки зрения:

$(\bar{x}, \bar{x}, \dots, \bar{x})$  — проекция вектора  $\mathbf{x}$  на  $\text{Span } \mathbf{v}$ , где  $\mathbf{v} = (1, 1, \dots, 1)$ .

$(x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x})$  — проекция вектора  $\mathbf{x}$  на  $\text{Span}^\perp \mathbf{v}$ .

# Выборочная дисперсия

## Определение

Выборочной дисперсией набора чисел  $(x_1, x_2, \dots, x_n)$  называют величину  $\|\mathbf{x}'\|^2 / (n - 1)$ , где вектор  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ .

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$

# Выборочная дисперсия

## Определение

Выборочной дисперсией набора чисел  $(x_1, x_2, \dots, x_n)$  называют величину  $\|\mathbf{x}'\|^2 / (n - 1)$ , где вектор  $\mathbf{x}'$  — это центрированный вектор  $\mathbf{x}$ .

$$\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}.$$

Выборочная дисперсия вектора показывает «разброс»  $x_i$ , насколько далеки  $x_i$  от своего среднего  $\bar{x}$ .

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

Выборочным стандартным отклонением набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

Выборочным стандартным отклонением набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

# Стандартное отклонение

Если  $x_i$  измеряется в сантиметрах, то выборочная дисперсия измеряется в квадратных сантиметрах.

## Определение

Выборочным стандартным отклонением набора  $\mathbf{x}$  называется корень из выборочной дисперсии

$$sd(\mathbf{x}) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

Если  $x_i$  измеряется в сантиметрах, то выборочное стандартное отклонение измеряется в сантиметрах.

# Стандартизация

Популярным вариантом масштабирования переменной является переход к безразмерной величине по принципу:

$$x_i \rightarrow \frac{x_i - \bar{x}}{sd(\mathbf{x})}.$$

# Стандартизация

Популярным вариантом масштабирования переменной является переход к безразмерной величине по принципу:

$$x_i \rightarrow \frac{x_i - \bar{x}}{sd(\mathbf{x})}.$$

После стандартизации величина имеет нулевое среднее и единичное стандартное отклонение.

# Выборочная корреляция

## Определение

Выборочной корреляцией двух наборов чисел  $\mathbf{x}$  и  $\mathbf{y}$  называют косинус угла между их центрированными версиями:

$$\rho(\mathbf{x}, \mathbf{y}) = \cos \angle(\mathbf{x}', \mathbf{y}') = \frac{\langle \mathbf{x}', \mathbf{y}' \rangle}{\|\mathbf{x}'\| \|\mathbf{y}'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .

# Выборочная корреляция

## Определение

Выборочной корреляцией двух наборов чисел  $x$  и  $y$  называют косинус угла между их центрированными версиями:

$$\rho(x, y) = \cos \angle(x', y') = \frac{\langle x', y' \rangle}{\|x'\| \|y'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .

Не определена, если  $x$  или  $y$  состоит из одинаковых чисел.

# Выборочная корреляция

## Определение

Выборочной корреляцией двух наборов чисел  $x$  и  $y$  называют косинус угла между их центрированными версиями:

$$\rho(x, y) = \cos \angle(x', y') = \frac{\langle x', y' \rangle}{\|x'\| \|y'\|},$$

где  $x'_i = x_i - \bar{x}$  и  $y'_i = y_i - \bar{y}$ .

Не определена, если  $x$  или  $y$  состоит из одинаковых чисел.

Лежит в диапазоне от  $-1$  до  $1$ .

# Выборочная корреляция

## Утверждение

Выборочная корреляция равна

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2} \sqrt{\sum(y_i - \bar{y})^2}}.$$

Если после центрирования векторы ортогональны, то выборочная корреляция равна 0.

# Выборочная корреляция

## Утверждение

Выборочная корреляция равна

$$\rho(\mathbf{x}, \mathbf{y}) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2} \sqrt{\sum(y_i - \bar{y})^2}}.$$

Если после центрирования векторы ортогональны, то  
выборочная корреляция равна 0.

Не чувствительна к масштабированию.

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(\mathbf{x}_i, \mathbf{x}_j)$$

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(x_i, x_j)$$

Если переменные  $x_1, x_2, \dots, x_k$  стандартизированы, то  $C = X^T X$ .

# Выборочная корреляционная матрица

## Определение

Выборочной корреляционной матрицей переменных  $x_1, x_2, \dots, x_k$  называется матрица  $C$ , элементами которой являются выборочные корреляции,

$$c_{ij} = \rho(x_i, x_j)$$

Если переменные  $x_1, x_2, \dots, x_k$  стандартизированы, то  $C = X^T X$ .

Матрица  $C$  симметрична и положительно полуопределенна.

# **PCA: максимизация разброса**

# Краткий план:

- Последовательное построение компонент.

# Краткий план:

- Последовательное построение компонент.
- Свойства компонент.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:  
наблюдения отложены по строкам, а переменные — по  
столбцам.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

А мы хотим визуализировать данные.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

А мы хотим визуализировать данные.

Или хотим иметь небольшое количество переменных, которые бы почти без потерь содержали всю информацию в исходных переменных.

# Метод главных компонент

Все исходные переменные предварительно  
стандартизируем!

# Метод главных компонент

Все исходные переменные предварительно  
стандартизируем!

Для каждого столбца  $x$  выполнены условия  $\bar{x} = 0, sd(x) = 1$ .

# Метод главных компонент

Все исходные переменные предварительно стандартизуем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

# Метод главных компонент

Все исходные переменные предварительно стандартизуем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

Новые переменные будем создавать по-очереди.

# Метод главных компонент

Все исходные переменные предварительно стандартизуем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

Новые переменные будем создавать по-очереди.

Новые переменные будем называть **главными компонентами**.

PCA — principal component analysis.

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .

# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .
2. Компоненту  $p_2 = Xv_2$  подберём так, чтобы выборочная дисперсия  $p_2$  была максимальной при условии, что  $v_2 \perp v_1$  и  $\|v_2\| = 1$ .

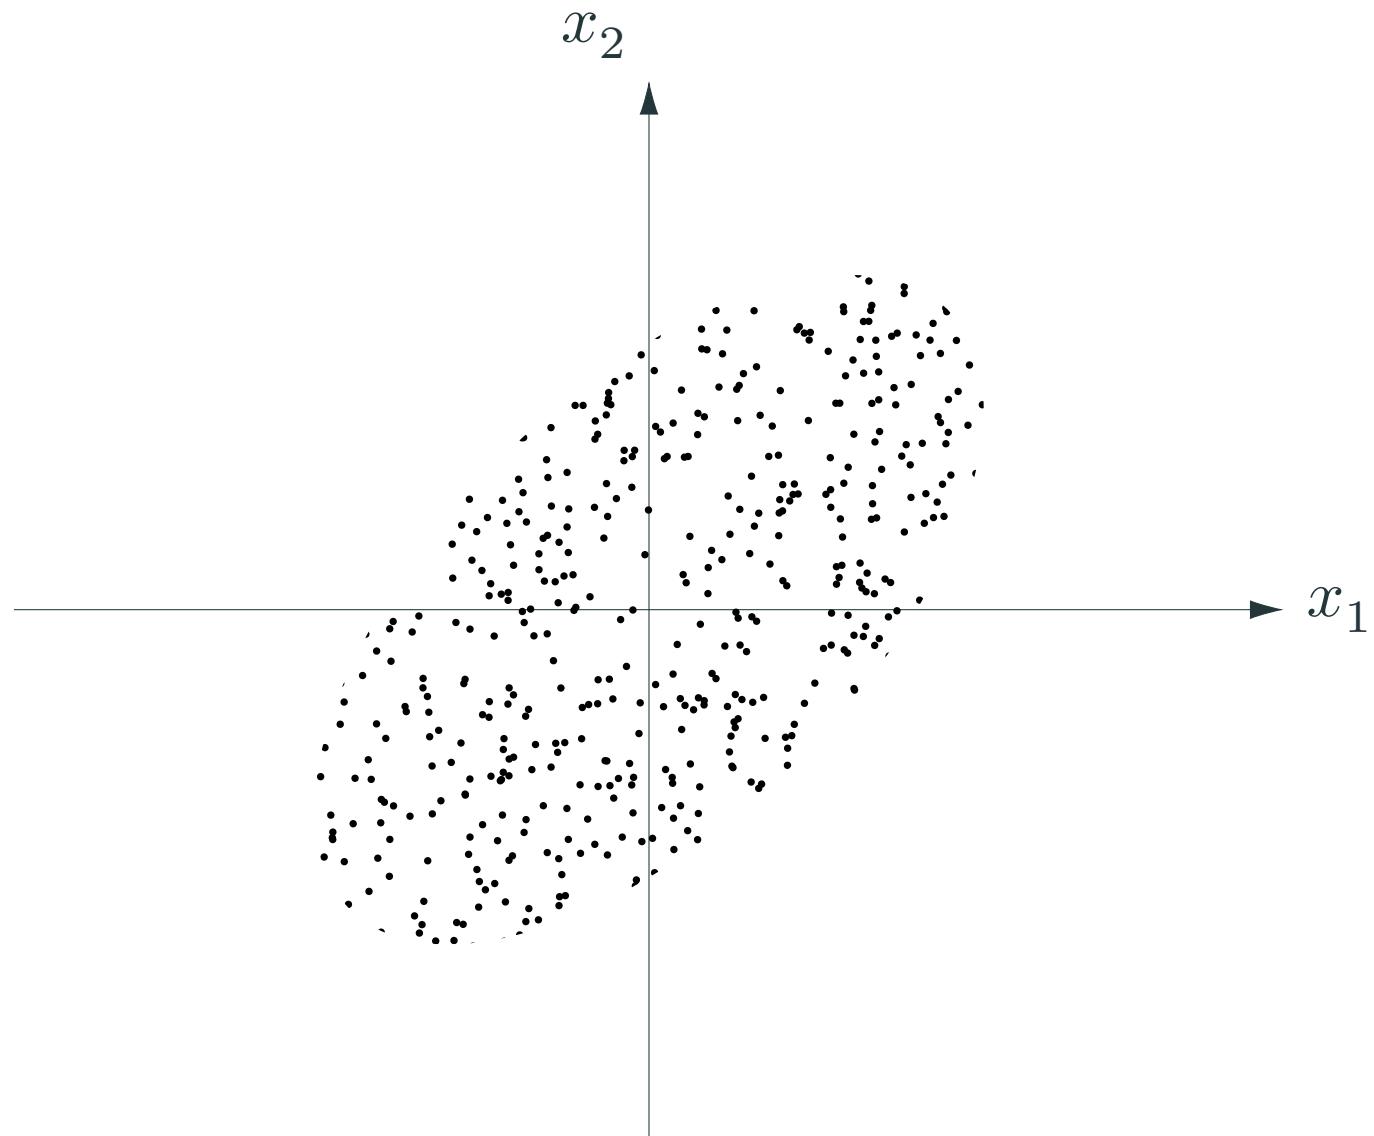
# Максимизация разброса

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

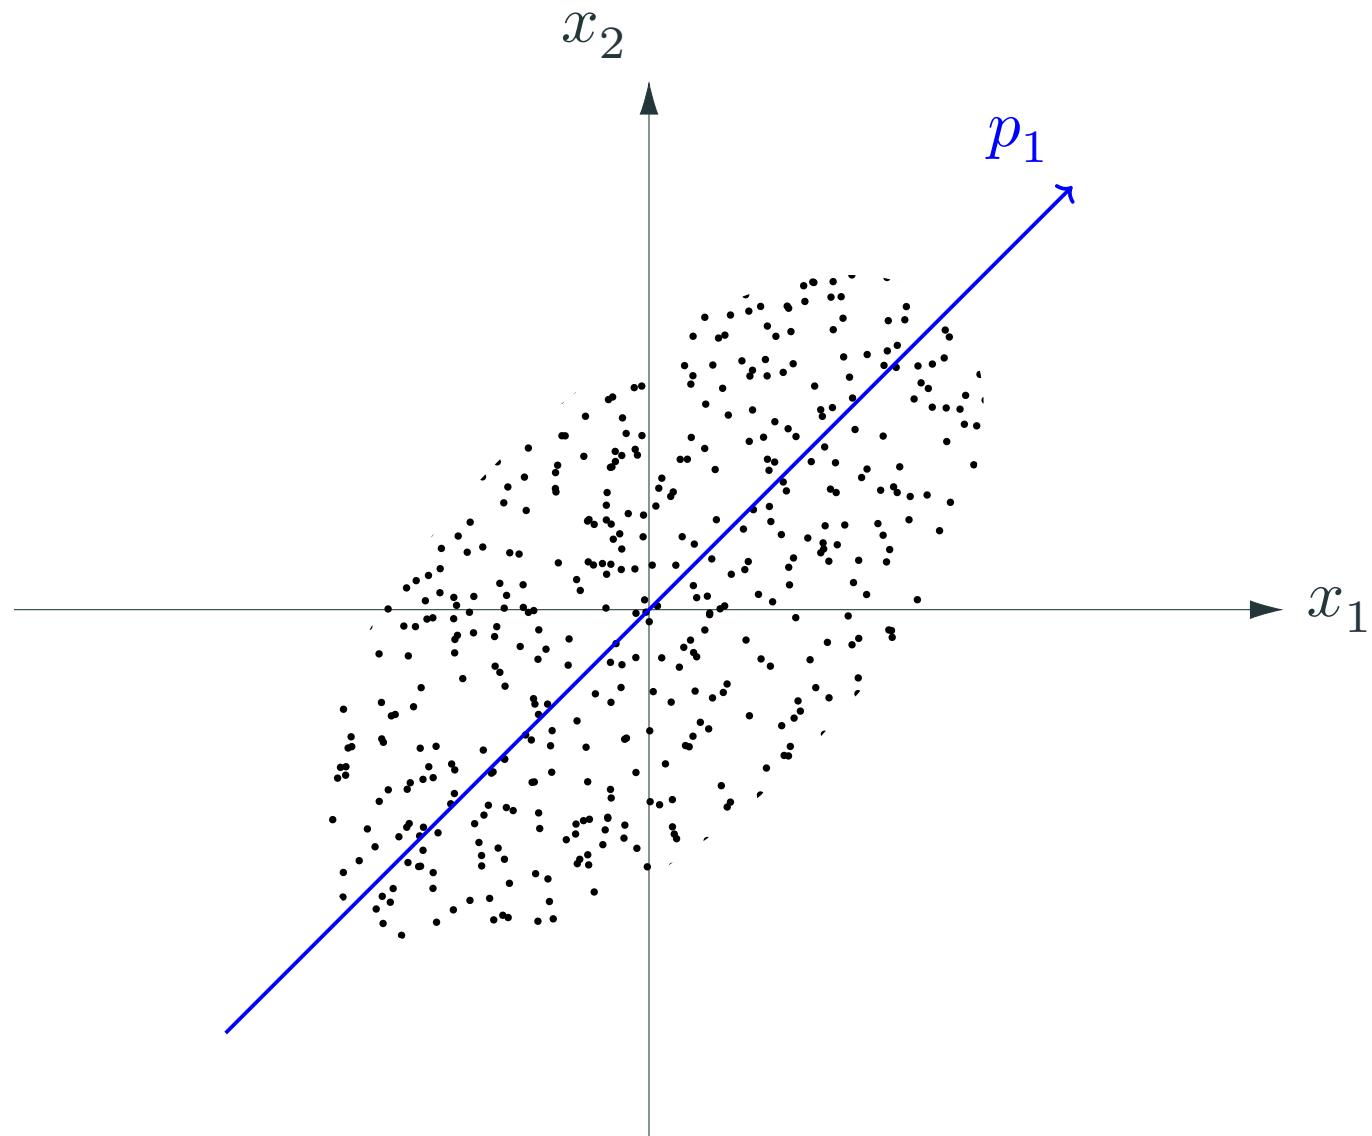
## Алгоритм

1. Компоненту  $p_1 = Xv_1$  подберём так, чтобы выборочная дисперсия  $p_1$  была максимальной при условии, что  $\|v_1\| = 1$ .
2. Компоненту  $p_2 = Xv_2$  подберём так, чтобы выборочная дисперсия  $p_2$  была максимальной при условии, что  $v_2 \perp v_1$  и  $\|v_2\| = 1$ .
3. Компоненту  $p_3 = Xv_3$  подберём так, чтобы выборочная дисперсия  $p_3$  была максимальной при условии, что  $v_3 \perp v_2, v_1$  и  $\|v_3\| = 1$ .
4. ...

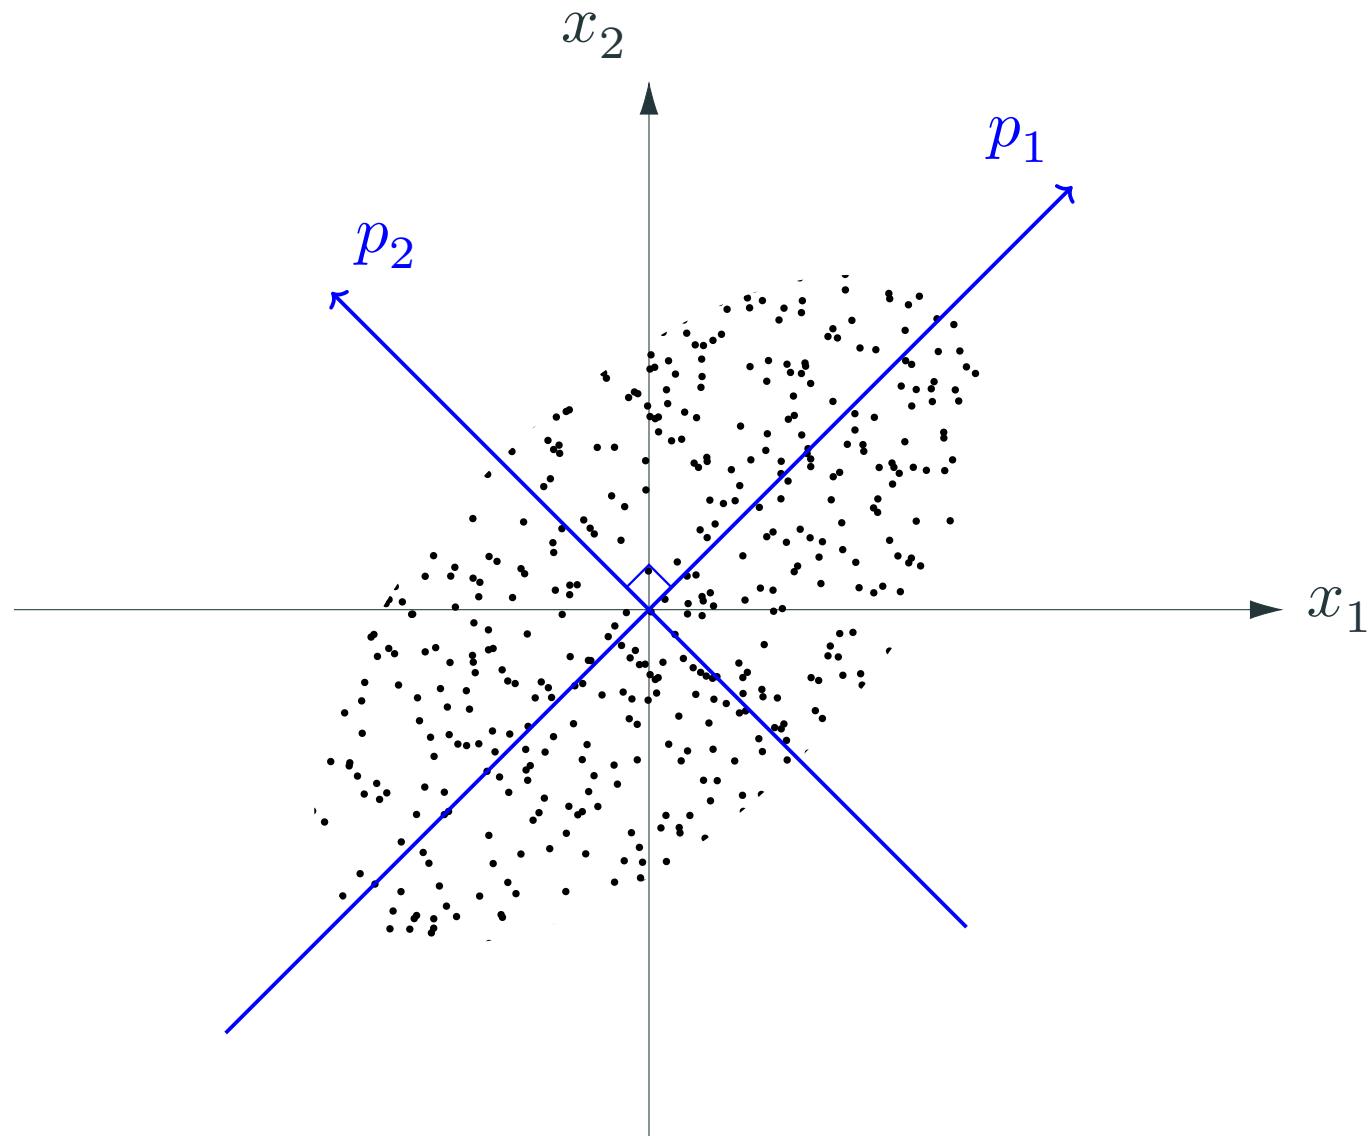
# Карти́нка



# Картина



# Картина



# Это завуалированный SVD!

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

# Это завуалированный SVD!

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

$$\begin{pmatrix} | & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & | \end{pmatrix} = \begin{pmatrix} | & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_k \\ | & | \end{pmatrix} \begin{pmatrix} | & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_k \\ | & | \end{pmatrix}$$
$$\begin{pmatrix} | & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & | \end{pmatrix} = \begin{pmatrix} | & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

# Это завуалированный SVD!

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

$$\begin{pmatrix} | & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & | \end{pmatrix} = \begin{pmatrix} | & | \\ \mathbf{x}_1 & \dots & \mathbf{x}_k \\ | & | \end{pmatrix} \begin{pmatrix} | & | \\ \mathbf{v}_1 & \dots & \mathbf{v}_k \\ | & | \end{pmatrix}$$
$$\begin{pmatrix} | & | \\ \mathbf{p}_1 & \dots & \mathbf{p}_k \\ | & | \end{pmatrix} = \begin{pmatrix} | & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & | \end{pmatrix} \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

# Свойства

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

# Свойства

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

Главные компоненты ортогональны.

Величины  $\sigma_i^2$  равны квадратам длин  $\|\mathbf{p}_i\|^2$  и пропорциональны выборочным дисперсиям  $p_i$ .

Достигаемое значение максимума суммы

$$\|\mathbf{p}_1\|^2 + \|\mathbf{p}_2\|^2 + \dots + \|\mathbf{p}_k\|^2$$

одинаковое при пошаговой и одновременной максимизации.

# Связь с корреляционной матрицей

Если  $X = U\Sigma V^T$ , то корреляционная матрица имеет вид  
 $C = X^T X = V\Sigma^T \Sigma V^T$ .

# Связь с корреляционной матрицей

Если  $X = U\Sigma V^T$ , то корреляционная матрица имеет вид  
 $C = X^T X = V\Sigma^T \Sigma V^T$ .

Векторы весов  $v_i$ , с которыми исходные переменные входят в компоненты, являются собственными векторами корреляционной матрицы  $C$ .

# Связь с корреляционной матрицей

Если  $X = U\Sigma V^T$ , то корреляционная матрица имеет вид  
 $C = X^T X = V\Sigma^T \Sigma V^T$ .

Векторы весов  $v_i$ , с которыми исходные переменные входят в компоненты, являются собственными векторами корреляционной матрицы  $C$ .

Сингулярные значения матрицы  $X$  в квадрате являются собственными числами корреляционной матрицы  $C$ ,  
 $\lambda_i = \sigma_i^2$ .

# **PCA: минимизация ошибки**

# Краткий план:

- Последовательное построение компонент.

# Краткий план:

- Последовательное построение компонент.
- Свойства компонент.

# Метод главных компонент

Есть матрица  $X$  исходных наблюдений:

наблюдения отложены по строкам, а переменные — по столбцам.

Переменных очень много.

А мы хотим визуализировать данные.

Или хотим иметь небольшое количество переменных, которые бы почти без потерь содержали всю информацию в исходных переменных.

# Поиск наилучшего приближения

Хотим найти матрицу  $\hat{X}$  такую, чтобы при заданном ранге  $\text{rank } \hat{X} = d$  матрица  $\hat{X}$  была бы поближе к  $X$ :

$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 = \text{tr}((X - \hat{X})^T(X - \hat{X})) \rightarrow \min$$

# Поиск наилучшего приближения

Хотим найти матрицу  $\hat{X}$  такую, чтобы при заданном ранге  $\text{rank } \hat{X} = d$  матрица  $\hat{X}$  была бы поближе к  $X$ :

$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 = \text{tr}((X - \hat{X})^T(X - \hat{X})) \rightarrow \min$$

Аппроксимация с рангом  $d$  обозначим  $\hat{X}_d$ .

# Метод главных компонент

Все исходные переменные предварительно стандартизуем!

Для каждого столбца  $\mathbf{x}$  выполнены условия  $\bar{x} = 0, sd(\mathbf{x}) = 1$ .

На базе столбцов  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k$  матрицы  $X$  мы создадим  $d \leq k$  новых переменных  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$ .

Новые переменные будем создавать по-очереди.

Новые переменные будем называть **главными компонентами**.

PCA — principal component analysis.

# Минимизация ошибки приближения

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

# Минимизация ошибки приближения

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

Матрица  $\hat{X}_i$  содержит проекции столбцов матрицы  $X$  на  $\text{Span}\{p_1, p_2, \dots, p_i\}$ .

## Алгоритм

- Компоненту  $p_1 = Xv_1$  подберём так, чтобы матрица  $\hat{X}_1$  была наилучшей аппроксимацией  $X$ ,

$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 \rightarrow \min.$$

# Минимизация ошибки приближения

Главные компоненты  $p_1, p_2, \dots, p_d$  будут линейными комбинациями столбцов  $X$ .

Матрица  $\hat{X}_i$  содержит проекции столбцов матрицы  $X$  на  $\text{Span}\{p_1, p_2, \dots, p_i\}$ .

## Алгоритм

- Компоненту  $p_1 = Xv_1$  подберём так, чтобы матрица  $\hat{X}_1$  была наилучшей аппроксимацией  $X$ ,

$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 \rightarrow \min.$$

- Компоненту  $p_2 = Xv_2$  подберём так, чтобы матрица  $\hat{X}_2$  была наилучшей аппроксимацией  $X$ ,

$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 \rightarrow \min \text{ при условии, что } v_2 \perp v_1 \text{ и } \|v_2\| = 1.$$

# Минимизация ошибки приближения

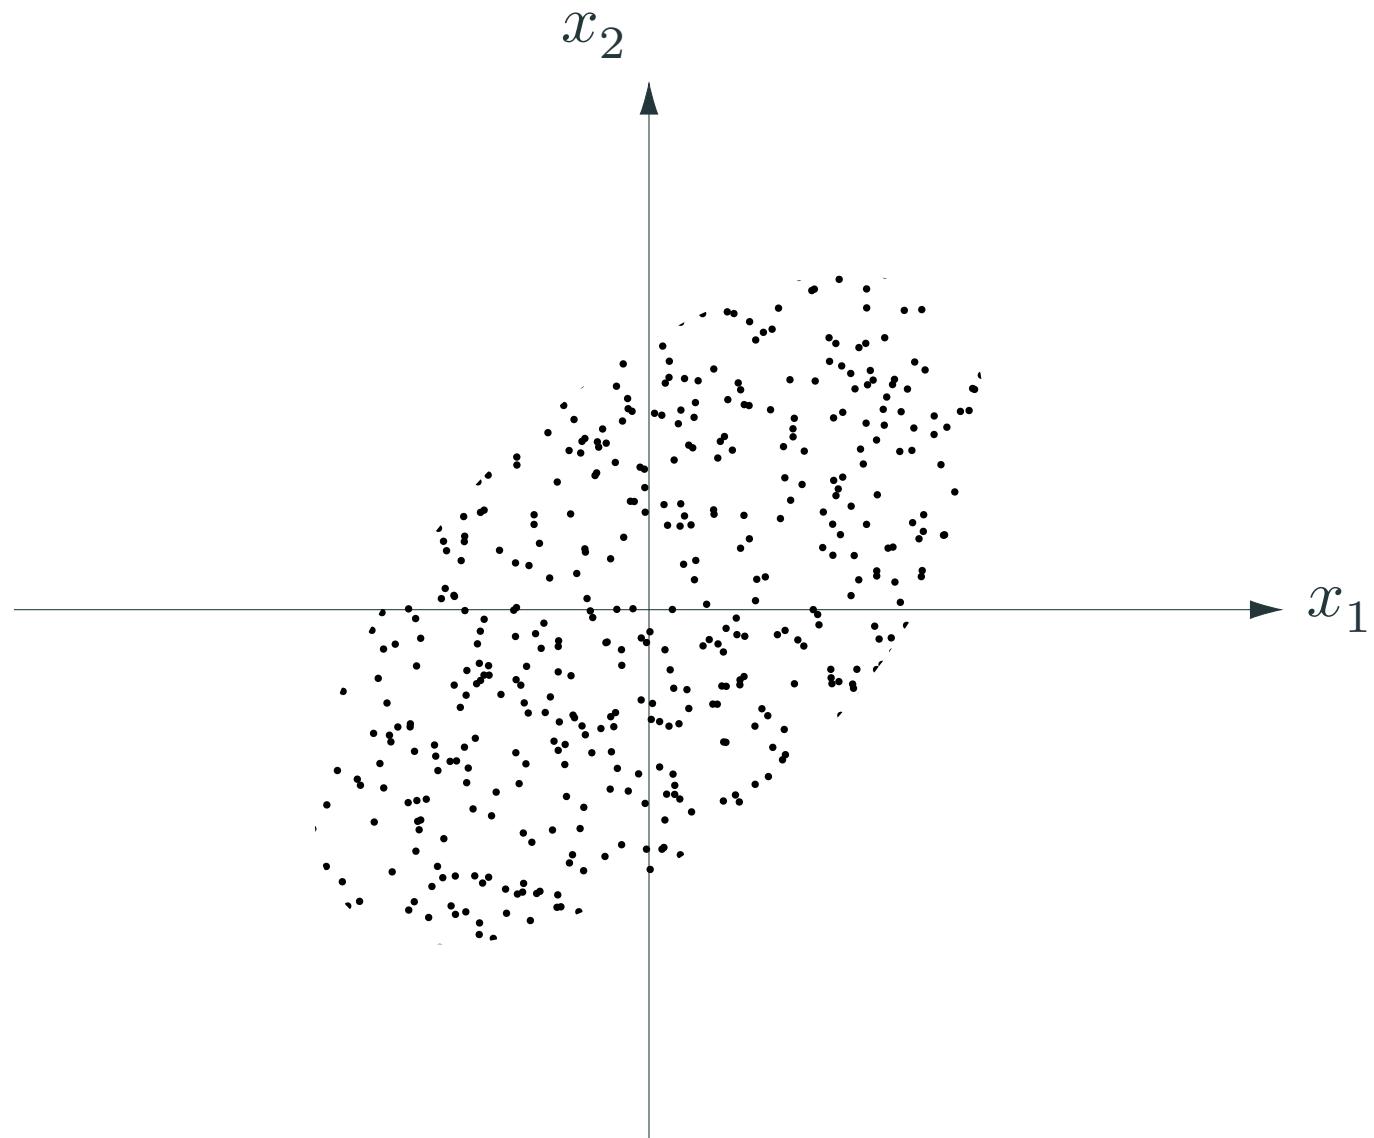
Главные компоненты  $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_d$  будут линейными комбинациями столбцов  $X$ .

Матрица  $\hat{X}_i$  содержит проекции столбцов матрицы  $X$  на  $\text{Span}\{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_i\}$ .

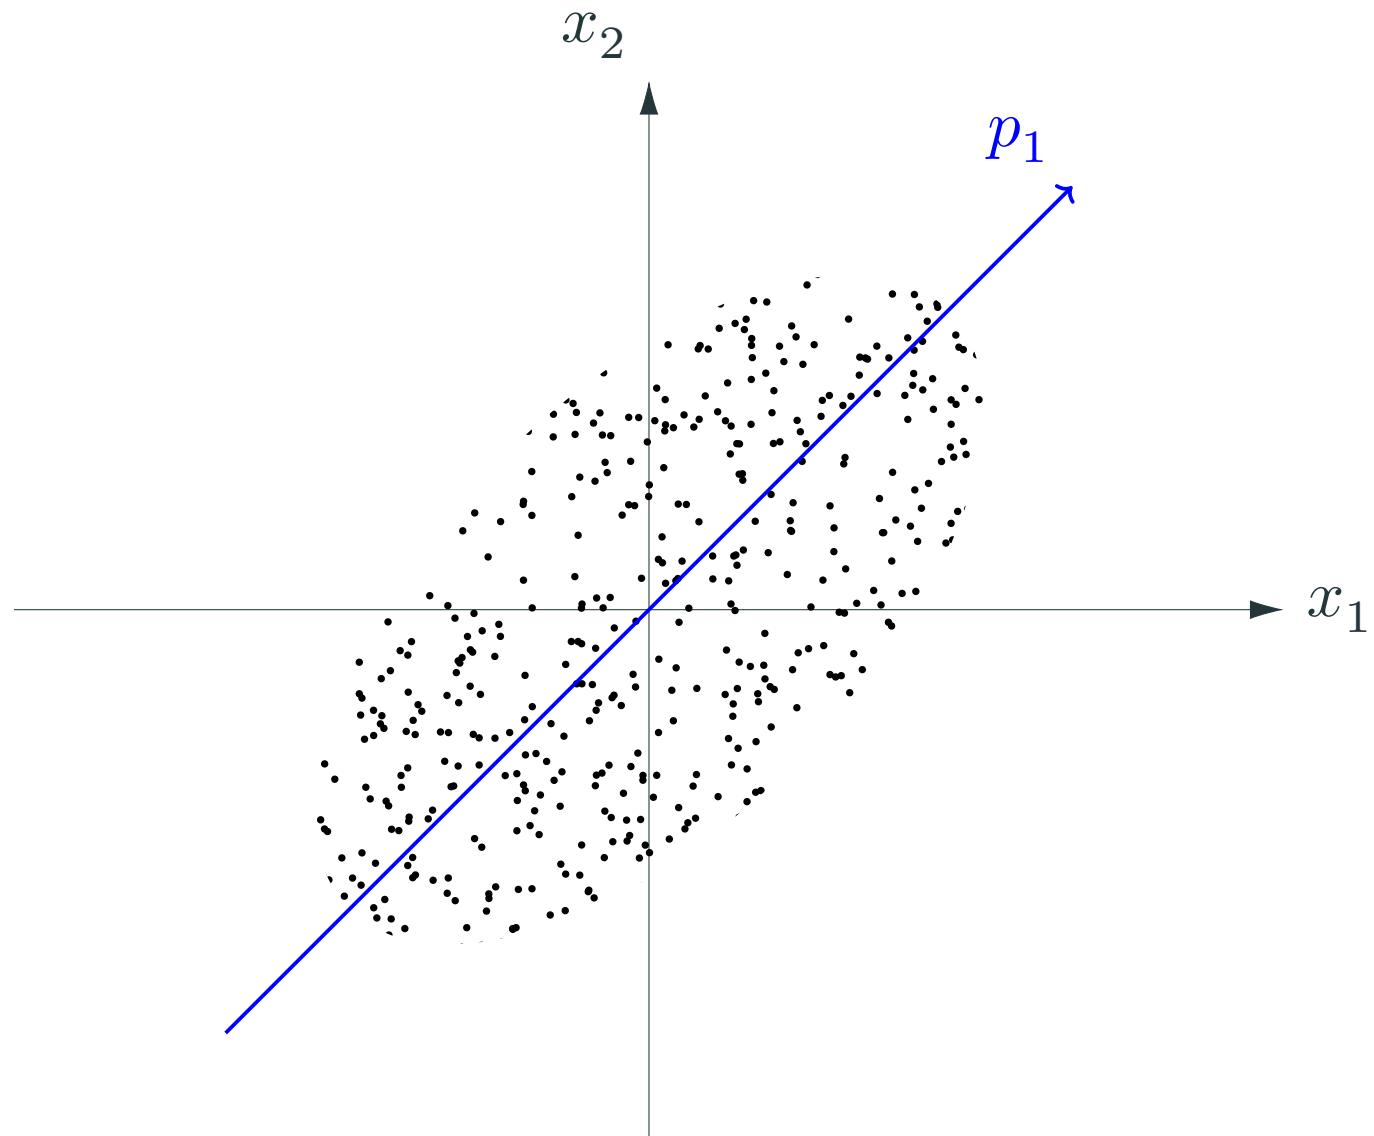
## Алгоритм

- Компоненту  $\mathbf{p}_1 = X\mathbf{v}_1$  подберём так, чтобы матрица  $\hat{X}_1$  была наилучшей аппроксимацией  $X$ ,  
$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 \rightarrow \min.$$
- Компоненту  $\mathbf{p}_2 = X\mathbf{v}_2$  подберём так, чтобы матрица  $\hat{X}_2$  была наилучшей аппроксимацией  $X$ ,  
$$\sum_{ij} (x_{ij} - \hat{x}_{ij})^2 \rightarrow \min$$
 при условии, что  $\mathbf{v}_2 \perp \mathbf{v}_1$  и  
$$\|\mathbf{v}_2\| = 1.$$
- ...

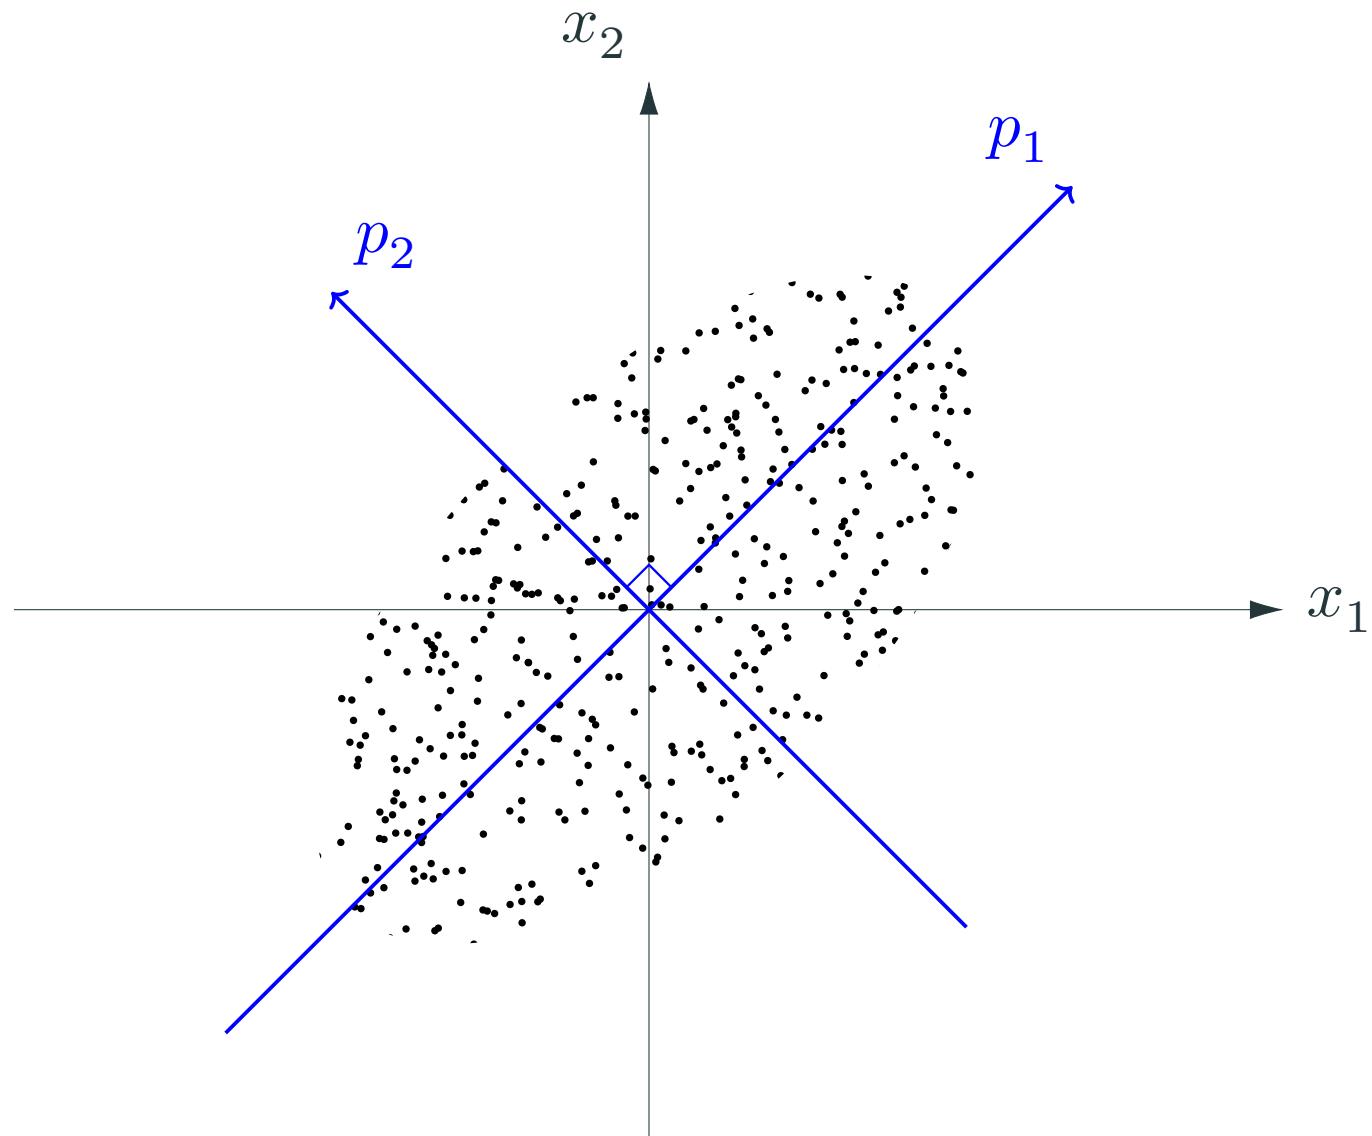
# Карти́нка



# Картина



# Картина



# И это завуалированный SVD!

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

# И это завуалированный SVD!

Если  $X = U\Sigma V^T$ , то  $P = XV = U\Sigma$ .

Аппроксимация  $\hat{X}_d$  с рангом  $\text{rank } \hat{X}_d = d$  строится так:

$$\hat{X}_d = U\Sigma_d V^T,$$

где матрицу  $\Sigma_d$  получили из матрицы  $\Sigma$  оставив в ней только  $d$  штук самых больших сингулярных значений и занулив остальные.

# Свойства

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

Главные компоненты ортогональны.

Величины  $\sigma_i^2$  равны квадратам длин  $\|\mathbf{p}_i\|^2$  и пропорциональны выборочным дисперсиям  $p_i$ .

# Свойства

Главные компоненты находятся из  $SVD$  разложения,

$$\mathbf{p}_i = \sigma_i \mathbf{u}_i.$$

Главные компоненты ортогональны.

Величины  $\sigma_i^2$  равны квадратам длин  $\|\mathbf{p}_i\|^2$  и пропорциональны выборочным дисперсиям  $p_i$ .

Значение максимума суммы

$$\|\mathbf{p}_1\|^2 + \|\mathbf{p}_2\|^2 + \dots + \|\mathbf{p}_k\|^2$$

одинаковое при пошаговой и одновременной максимизации.

# **Скринкаст: SVD для снижения размерности**

**Это видеофрагмент с доской, слайдов здесь нет :)**

## **Бонус: геометрическая алгебра**

**Это видеофрагмент с доской, слайдов здесь нет :)**